

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/320173201>

Clustering Learning Objects in the IEEE-LOM Standard Considering Learning Styles to Support Customized Recommendation Systems in Educational Environments

Conference Paper · October 2017

DOI: 10.1109/LACLO.2017.8120898

CITATIONS

0

READS

48

5 authors, including:



Miller Mendes

Universidade Federal de Uberlândia (UFU)

8 PUBLICATIONS **6** CITATIONS

[SEE PROFILE](#)



Vitor César de Carvalho

Universidade Federal de Uberlândia (UFU)

11 PUBLICATIONS **23** CITATIONS

[SEE PROFILE](#)



Rafael Dias Araújo

Universidade Federal de Uberlândia (UFU)

27 PUBLICATIONS **57** CITATIONS

[SEE PROFILE](#)



Fabiano Dorça

Universidade Federal de Uberlândia (UFU)

55 PUBLICATIONS **220** CITATIONS

[SEE PROFILE](#)

Some of the authors of this publication are also working on these related projects:



Using machine learning and semantic web technologies to support reuse and personalized recommendation of content in adaptive educational systems considering students learning styles [View project](#)



Learning Objects Authoring and Personalization Supported by Ubiquitous Learning Environments [View project](#)

Clustering Learning Objects in the IEEE-LOM Standard Considering Learning Styles to Support Customized Recommendation Systems in Educational Environments

Miller M. Mendes, Vitor C. Carvalho, Rafael D. Araújo, Fabiano A. Dorça, Renan G. Cattelan

Faculdade de Computação, Universidade Federal de Uberlândia, Brazil

Email: m3iller@gmail.com, vitorcarvalho@comp.ufu.br, rafael.araujo@ufu.br, fabianodor@ufu.br, renan@ufu.br

Abstract—Adapting an educational environment to students considering its features and individuals is a necessity due to the large amount of learning objects in the repositories. Thus, organizing learning objects so that they can be efficiently recommended is a real need. In this way, this work presents a proposal for clustering learning objects in repositories considering the learning styles they support, in order to facilitate the content recommendation process based on students' learning styles. For this, a comparative analysis of clustering techniques was performed, and the most efficient was used in the implementation of this approach. Experiments were conducted and promising results were obtained.

keywords: *learning objects, learning styles, adaptive educational systems, clustering, learning environment, lom field*

1. Introdução

Os sistemas educacionais utilizam a tecnologia como uma forma de apoiar e facilitar o ensino dos professores, seja em aulas presenciais ou aulas a distância [1]. Diante disso, tem-se a necessidade de criar novas ideias e algoritmos para que a informação gerada em aulas possa ser melhorada com o apoio da tecnologia.

Os Ambientes Virtuais de Aprendizagem (AVA) fornecem maneiras de interação entre sistemas, professores e estudantes, utilizando linguagens e recursos tecnológicos para exibição de informação de forma organizada [2]. O uso de AVA no meio acadêmico tem se tornando cada vez mais importante e, consequentemente, mais utilizado [3]. Dessa forma, adequar tais ambientes ao estudante, considerando suas características e individualidades, é uma necessidade real.

Para isso, a utilização de Objetos de Aprendizagem (OA) tem sido uma abordagem promissora [4]. O *Learning Technology Standards Committee* (LTSC), dentro do *Institute of Electrical and Electronics Engineers* (IEEE), tem adotado a definição de OA como qualquer entidade digital ou não-digital que pode ser utilizada para o aprendizado no meio da educação.

Um conceito importante para a criação de sistema de recomendação de conteúdo personalizada são os Estilos

de aprendizagem (EAs), que estão diretamente ligados às estratégias em que um estudante adota para realizar seu aprendizado. Felder e Silverman [5] propõem um modelo específica para o aprendizado de estudantes por meio de quatro dimensões: percepção, entrada, processamento e organização.

Segundo [6], um ponto importante em direção a construção de um projeto que possa recomendar automaticamente conteúdo de aprendizagem para estudantes é a identificação das melhores formas de organização dos OAs, no qual seja possível uma melhoria na qualidade e efetividade do processo de recomendação.

Repositórios de OAs foram criados para facilitar a busca desses objetos a partir das áreas, conteúdos e tipos (áudio, vídeo, diagramas, texto, etc.). No entanto, observa-se que os repositórios possuem uma grande quantidade de dados, o que resulta em OAs que não atendem a um determinado perfil do aluno. Neste sentido, Cazella et al. [7] propõem a criação de sistemas que possibilitam auxiliar o usuário na busca e seleção de um conteúdo com base em seu perfil.

Neste sentido, recomendar conteúdo considerando o perfil do estudante é um estudo relevante. As recomendações são realizadas relacionando características que são importantes em um determinado contexto. Para realizar a recomendação no contexto educacional, avaliar as ações do aluno quando este interage com determinados conteúdos é de grande importante para avaliar as características individuais [8].

A clusterização (ou agrupamento) é uma técnica que pode ser aplicada para aumentar a escalabilidade de sistemas de recomendação, na qual OAs podem ser agrupados utilizando métricas de similaridade. Logo, a recomendação de OAs pode ser aplicada em grupos específicos gerados em cada agrupamento.

Assim, este trabalho apresenta uma proposta que leva em consideração a relação entre os EAs de Felder e Silverman e os metadados IEEE-LOM dos OAs, utilizando uma estratégia para vetorizar os OAs para facilitar o processo agrupamento. Com isso, torna-se possível utilizar técnicas de agrupamentos que auxiliam o processo de recomendação por EAs, tornando-o mais eficiente, uma vez que possibilita um pré-processamento das características dos EAs atendidos

pelos OAs.

As próximas páginas serão divididas em seções, onde a Seção 2 apresenta trabalhos relacionados; na Seção 3 são descritos os conceitos relevantes para o entendimento deste trabalho; a Seção 4 descreve a abordagem proposta; a Seção 5 apresenta os resultados obtidos; e, por fim, a Seção 6 traz as considerações finais acerca do trabalho.

2. Trabalhos Relacionados

Modelos de recomendação de conteúdo tem sido amplamente aplicados em diversos ambientes educacionais, como exemplo [9] apresenta uma abordagem de sistema de recomendação de OAs utilizando filtragem colaborativa e competências. O modelo entrega aos alunos a recomendação de OA de forma automática com base nos interesses do aluno e suas respectivas competências que devem ser desenvolvidas dentro de um plano de aula. Esta proposta não utiliza o modelo de Felder e Silverman para avaliar o perfil de aprendizagem do estudante.

O modelo proposto em [10] é baseado em aplicar um algoritmo de filtragem colaborativa em clusters de OAs e de usuários. Foi realizado uma clusterização com base em conteúdo de duas formas, com os OAs e usuários, para gerar a recomendação. Entretanto, este modelo não utiliza a relação entre OAs e EAs para recomendação.

Casagrande et al. [11] apresentam uma técnica proposta e avalia valores dos elementos de metadados dos conteúdos acessados pelos usuários a fim de estimar as suas preferências e formular a recomendação. O objetivo é determinar as preferências do usuário a partir dos dados que descrevem os conteúdos acessados pelo estudante. O conjunto de elementos de metadado a ser observado é dependente do domínio do repositório, permitindo que metadados descritores de objetos de aprendizagem sejam considerados.

O trabalho apresentado em [12] apresenta uma metodologia adaptada para produzir regras sobre OAs considerando as características de usabilidade. Utilizando uma metodologia de extração de conhecimento de OAs através da utilização de quatro bases de dados: metadados, avaliações de qualidade pedagógica, perfis de usuário, e arquivos de log de OAs em um sistemas de gestão. Este trabalho não utiliza a relação entre EAs e OAs para obter resultados.

Um estudo realizado por [13] aborda uma estratégia de sugestão utilizando links para personalizar a relação do usuário baseado em algoritmos de mineração que avaliam log do estudante. As recomendações de conteúdo tem como base links cadastrados no curso feito pelo tutor. Entretanto, a relação entre os OA e os perfis não é realizada de maneira automatizada, sendo necessário que o tutor crie essa conexão.

Este trabalho se destaca por realizar agrupamentos de acordo com os EAs atendidos pelos OAs, considerando as 16 combinações possíveis de EAs dentro do modelo de Felder e Silverman. Este modelo propõe uma forma vetorial de representar os OAs considerando os EAs que eles atendem, tornando o processo de recomendação por EAs muito mais

eficientes, e com o resultado desta vetorização se torna possível aplicar técnicas de agrupamentos.

Portanto, a proposta de agrupamento de OAs pode se tornar uma ideia com ótima contribuição para as estratégias de recomendação de conteúdo personalizada, por ser independente de um repositório ou AVA específico, sendo que a única restrição é que OAs tenham metadados em formato IEEE-LOM. Com isso, pode-se então acoplar em qualquer sistema que precise personalizar a recomendação de conteúdo.

3. Fundamentação Teórica

Nesta sessão, são apresentadas as definições e os conceitos necessários para o entendimento da abordagem proposta, além de citar trabalhos relacionados ao tema desta pesquisa. Serão apresentados os conceitos proposto por Felder and Silverman e o padrão utilizado para os objetos de aprendizagem.

3.1. Relação entre Estilos de Aprendizagem e Objetos de Aprendizagem

Estilo de Aprendizagem, segundo [14], consiste no modo preferencial, individual e habitual no qual os indivíduos possuem organizar e representar informações durante o processo de aprendizagem. Neste trabalho, será utilizado o modelo FSLSM [5] que é amplamente utilizado para adaptação e personalização dos materiais de aprendizagem. O modelo de Felder foi definido em quatro dimensões e dentro de cada dimensão foram definidos dois EAs antagônicos sendo Intuitivo/Sensitivo, Ativo/Reflexivo, Sequencial/Global e Visual/Verbal. O modelo de Felder é amplamente utilizado em vários trabalhos que utilizam estilos de aprendizagem [15], [16]. Cada um dos EAs desse modelo é sumarizado abaixo:

- Sensitivo: prefere aprender fatos, resolver problemas por métodos bem padronizados e não gosta de complicações.
- Intuitivo: prefere descobrir possibilidades e relações como inovação e não gosta de repetições.
- Ativo: compreende melhor a informação melhor fazendo algo relacionado, gosta de trabalhar em grupo.
- Reflexivo: compreende melhor a informação refletindo sobre o tema e gosta de trabalhar sozinho.
- Sequencial: aprendizado por etapas lineares, acompanhar passos gradativos lógicos na busca de soluções.
- Global: aprende com grandes saltos, resolve problemas complexos rapidamente, uma vez que foi compreendido o problema.
- Visual: aprende melhor vendo imagens, diagramas, fluxogramas, linhas de tempo, filmes, e demonstrações
- Verbal: prefere explicações com escritas e falas.

Conforme [17], um OA representa qualquer recurso digital que pode ser reutilizado para assistir à aprendizagem,

e distribuídos pela rede sob demanda. Neste trabalho, será utilizado a proposta do LTSC/IEEE Learning Object Metadata (LOM) [18] como padrão de documento de metadados para descrição de OAs. O padrão IEEE-LOM define OA como qualquer entidade que pode ser utilizada na área da educação. A Figura 1 apresenta graficamente os campos do padrão LOM.

Os conteúdos recomendados ao aluno podem ser organizados por meio da catalogação de metadados inserindo valores aos atributos definidos no padrão IEEE-LOM podendo representar este conteúdo como um OA, este padrão utiliza nove categorias para representar um OA:

- 1) Geral: representa informações gerais
- 2) Ciclo de Vida: representa histórico e estado atual
- 3) Meta-metadata: exibe informações sobre os metadados
- 4) Técnicos: representam requisitos técnicos
- 5) Direitos: exibe os direitos, propriedade intelectual e condições de uso
- 6) Educacional: informações relacionadas aos aspectos educacionais
- 7) Relação: informa relacionamentos entre os OAs
- 8) Anotação: informa comentários sobre o uso educacional
- 9) Classificação: informa o posicionamento do OA frente a sistemas de classificação pré-definido.

Diante disso, um importante ponto para utilizar OAs destaca-se no fato que sejam reutilizados para outras disciplinas diferentes das que foram criadas inicialmente. Recomendações são permitidas com base em características relacionadas ao escopo em um determinado contexto. Um sistema de recomendação em um contexto educacional avalia as ações do aluno durante a interação com alguns conteúdos para que possível sugerir e recomendar materiais de acordo com a preferência [19].

A categoria Educacional do LOM é de fundamental importância para este trabalho para relacionar os OAs com EAs, pois traz importantes características educacionais e pedagógicas dos OAs [20]. Esta é a informação pedagógica essencial para aqueles que estão envolvidos na experiência de aprendizagem. O foco para este metadado inclui professores, gerentes, autores, e aprendizes.

- Interactivity type: Este campo indica o modo predominante de aprendizagem suportado por um OA. Permite descobrir se um OA possui conteúdo que exige participação do estudante ou se ele traz conteúdo puramente expositivo. Portanto, permite verificar se um OA deve ser recomendado a um estudante ativo ou reflexivo.
- Learning Resource Type: Este campo indica o tipo específico do OA. Permite verificar se um OA deve ser recomendado para um estudante sensitivo ou intuitivo. Além disso, este campo permite verificar se um OA deve ser recomendado a um estudante verbal ou visual. Portanto com o uso dessas informações é possível recomendar um OA a um estudante ativo ou reflexivo.

- Interactivity Level: Este campo indica o grau de interatividade de um OA. Neste contexto, a interatividade refere-se ao grau de influência e o aspecto ou comportamental de um OA. Permite identificar se um OA é mais apropriado para um estudante ativo ou para um reflexivo.

Além desses campos da categoria Educacional, esta abordagem considera o campo *Structure* da categoria Geral e o campo *Format* da categoria Técnica.

- Structure: Este campo sugere a estrutura organizacional subjacente de um OA, e permite verificar se o OA é mais apropriado para um aluno global ou sequencial
- Format: Mostra o tipo de dados técnico de um OA, e permite determinar se um OA pode ser recomendado para um aluno sensitivo. Além disso o conteúdo deste campo é possível decidir se um OA deve ser recomendado para um estudante verbal ou visual. Também é possível identificar se um OA é mais apropriado a um estudante ativo ou reflexivo.

As recomendações devem sugerir conteúdo com base nas expectativas dos usuários, alguns sistemas de recomendação proposto por [9] visam auxiliar o usuário na busca e seleção de um conteúdo focado em seu perfil. Assim, o usuário terá como resultado de busca apenas os materiais mais próximos e relevantes.

Logo, utilizar técnicas de classificação com aprendizado de máquina para melhorar o processo de recomendação de conteúdo se torna um fator de relevância na área de educação [21].

3.2. Aprendizado de Máquina

O Aprendizado de Máquina pode ser descrito como o desenvolvimento de técnicas computacionais sobre o aprendizado, bem como a construção de sistemas capazes de adquirir conhecimento de forma automática [22]. A intuição humana não pode, nesse caso, ser totalmente abandonada, desde que o programador do sistema apresente os dados representados e o mecanismos usados para sua caracterização. Existem três tipos de aprendizado de máquina:

- Aprendizado supervisionado são treinados usando exemplos rotulados, como uma entrada onde a saída desejada é conhecida. Por exemplo, uma peça de equipamento pode ter pontos de dados rotulados com “F” (com falha) ou “R” (em funcionamento). O algoritmo de aprendizagem recebe um conjunto de entradas junto com as saídas corretas correspondentes, e o algoritmo aprende comparando a saída real com as saídas corretas para encontrar erros. Em seguida, ele modifica o modelo de acordo;
- Aprendizado não supervisionado é usado contra a dados que não possuem rótulos históricos. O sistema não sabe a “resposta certa”. O algoritmo deve descobrir o que está sendo mostrado. O objetivo é explorar os dados e encontrar alguma estrutura neles.

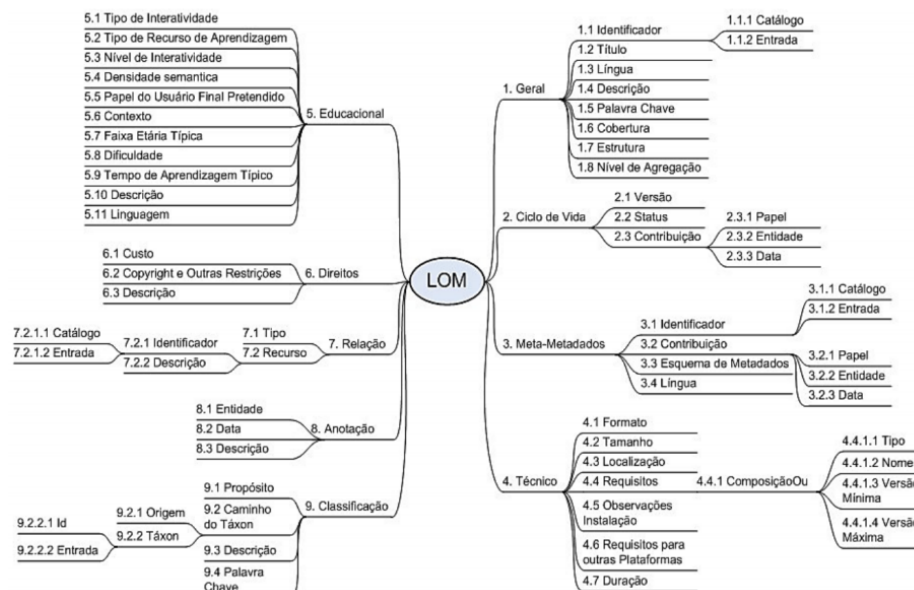


Figure 1. Metadados IEEE LOM

O aprendizado não supervisionado funciona bem em dados transacionais;

- Aprendizado semi supervisionado é usado para as mesmas aplicações que o aprendizado supervisionado. Mas ele usa tanto dados rotulados quanto não marcados para o treinamento — normalmente uma pequena quantidade de dados rotulados com uma grande quantidade de dados não rotulados (pois os dados não rotulados são mais baratos e precisam de menos esforço para serem adquiridos).

Neste trabalho foi utilizado a abordagem de aprendizado não supervisionado.

3.3. Clusterização

A clusterização é o processo de agrupamento de dados, utilizando algoritmos que avaliam a similaridade entre os atributos presentes dos dados. Com isso, pode-se dizer que elementos pertencente a um determinado cluster possuem características semelhantes entre si. O fato de agrupar os dados representa uma abordagem inerente para uma melhor compreensão dos dados sendo importante também para organizar dados similares. É importante citar alguns algoritmos que serão utilizados na abordagem proposta:

- K-Means: proposto por [23] que é um algoritmo que clusteriza dados em centroides, criados inicialmente de maneira aleatória, que são reajustados em direção ao centro dos clusters para serem reorganizados a cada iteração.
- Expectation Maximization (EM): [24] calcula probabilidades dos membros dos clusters com base em uma ou mais distribuições de probabilidade. O objetivo do algoritmo é de maximizar a probabilidade

global ou a probabilidade dos dados, dado os clusters finais.

- Self Organizing Map (SOM): a rede SOM proposto [25] que possui é uma rede neural de aprendizado competitivo, no qual os neurônios de uma camada competem entre si pelo privilégio de permanecerem ativos, onde um neurônio com maior atividade seja o único a participar do processo de aprendizado, criando assim clusters dos dados.

O processo de agrupamento podem resultar em diferentes particionamento de um conjunto de dados, dependendo do critério específico utilizado para clusterizar. Assim, existe uma necessidade de pré-processamento antes de assumir uma tarefa de agrupamento em um conjunto de dados. Os passos básicos para desenvolver processo de agrupamento são apresentados nas seguintes etapas: Seleção de Dados, Algoritmo de agrupamento, Validação dos Resultados e Interpretação dos Resultados [26].

Neste sentido, a relevância de agrupamentos no contexto de organizar os dados este trabalho irá organizar OAs utilizando técnicas de clusterização para recomendação personalizada de conteúdo.

4. Abordagem e Proposta

Nesta abordagem foi realizado um estudo de como agrupar OAs com características similares e, a partir desse agrupamento, poder recomendar conteúdo para um estudante conforme o seu EA correspondente.

A partir dos conceitos de EAs de [5] e OAs com utilizando padrão IEEE LOM foi realizado um estudo por [27] no qual foi estabelecido relações entre EAs e os metadados dos OAs no padrão IEEE-LOM, como pode-se observar

na Figura 3. Os campos *Structure*, *Format*, *Interactivity Type*, *Learning Resource Type* e *Interactivity Level* são campos que representam atributos de um determinado OA, considera-se que cada um desses atributos estão preenchidos, por exemplo *Format:video* que se encaixa no EA Visual. Com isso, pode-se representar um OA relacionado a um EA com base no conteúdo. Esse processo é mostrado na Figura 2.

O modelo apresentado 2 é uma visão simplificada do processo de execução, no qual os OAs estão disponibilizados em um repositório, posteriormente é executado o processo de vetorização e logo após é feito processamento dos vetores gerando os agrupamentos.



Figure 2. Processo de Agrupamento de OAs.

Para tornar possível o agrupamento, foi criado um método de vetorização com bases nos atributos dos OAs que consiste em contabilizar a quantidade de regras satisfeitas na Figura 3, por exemplo, um OA que atende a regra 4 contabiliza um ponto em relação ao estilo Global. Um OA que atende as regras 2, 4, 8, 10, 11, 15 pode ser representando na Tabela 1. Esse vetor possui oito parâmetros que são EAs de Felder e Silverman: Sensitivo(Sen), Intuitivo(Int), Ativo(Ati), Reflexivo(Ref), Sequencial(Seq), Global(Glo), Visual(Vis), Verbal(Ver).

Table 1. VETORIZAÇÃO DE UM OBJETO DE APRENDIZAGEM

Objeto de Aprendizagem x Felder e Silverman							
Sen.	Int	Ati.	Ref.	Seq.	Glo.	Vis.	Ver.
1	0	2	1	0	1	0	1

O modelo de Felder é formado por quatro dimensões, considerando a combinação entre essas dimensões tem-se como resultados 16 combinações, ou seja, 16 possíveis combinações de EAs [28]. Para validar os resultados, foi criado um rótulo para cada agrupamento, como exemplo um grupo que está nos EAs de Sensitivo, Ativo, Global e Verbal será representando da seguinte forma *SenAtiGloVer*. Portanto, nesta abordagem são considerados 16 possíveis clusters executados pelos algoritmos.

Durante o processo de validação dos resultados foram utilizadas duas ferramentas para auxiliar na execução dos algoritmos, Weka [29] e MatLab [30]. Foram gerados 1600 registros fictícios e consistentes em relação as regras da Figura 1 3, aleatórios e sem ordem. Nestes registros, foram gerados 100 elementos para cada combinação de EAs.

5. Resultados

Para realizar os experimentos, foram executados três algoritmos de clusterização: K-Means, EM e SOM. Foi

utilizado um histograma para visualizar a quantidade de OAs classificados em relação aos clusters. Conforme apresentado na Figura 4, pode-se observar que todos os algoritmos conseguiram clusterizar os OAs dentro das 16 combinações dos EAs.

Durante a execução da rede Neural SOM, foi utilizado um mapa 4x4 por serem esperados 16 clusters, considerando assim que cada neurônio representa um cluster. Em relação ao KMeans e EM, foram fixados o número de cluster em 16, visto que é necessário informar o número de grupos esperados nesses algoritmos. Com isso, pode-se dizer que houve coerência nos resultados obtidos inicialmente pois todos os OAs foram inseridos em grupos que eram esperados.

Posteriormente, a qualidade de cada cluster foi avaliada utilizando métricas de validação como Pureza(P), que valida se existem diferentes elementos em cada cluster, e *F-Measure* (F), que avalia a qualidade de cada cluster com base nos cálculos de *precision* e *recall* [31]. As métricas (M) são apresentadas na Tabela 2.

Neste contexto, com os dados apresentados na Tabela 2, os algoritmo K-Means e EM obtiveram melhores resultados pois possuem uma pureza e qualidade maior dos dados em cada cluster. O algoritmo SOM mostrou um alto grau de imprecisão nos cluster, pois as métricas mostram que cada cluster ficaram distribuídas pela metade, de modo geral. Logo, a utilização do K-Means e do EM se mostram favoráveis para o modelo. Sendo assim, o EM será utilizado pois levou um pequena vantagem com a métrica F em relação ao K-means.

Para a recomendação com EM é calculado o Grau de Pertinência(GP) que um determinado OA possui em um cluster, conforme a Tabela 3. O GP é a forma de representar o quanto um elemento pertence a um determinado grupo com base na similaridade. Com esta informação, é possível recomendar para um estudante um determinado conteúdo que seja similar aquele grupo, possibilitando recomendar OAs diferentes mesmo estando em clusters diferentes.

Portanto, essa abordagem se mostra promissora para uma recomendação de conteúdo automática personalizada com base em OAs e EAs de Felder. Conforme os resultados apresentados, esta abordagem está em direção para a recomendação de conteúdo em diferentes AVA tornando sistemas mais inteligentes e personalizados.

6. Implementação e Estudo de Caso

Um estudo de caso em uma plataforma com OAs reais foi implementado e está sendo utilizado como ferramenta complementar de aprendizagem em uma universidade federal brasileira de ensino superior. A plataforma, chamada de Classroom eXperience (CX) [32], utiliza conceitos de computação ubíqua para dar suporte à preparação do material pelo professor (fase chamada de pré-produção), gravar as aulas ministradas em sala de aula (fase chamada de gravação ao vivo) e disponibilizá-las posteriormente aos estudantes de forma personalizada (fase chamada de acesso).

A Figura 5 mostra uma visão de geral da integração do módulo de agrupamento proposto neste trabalho na

Structure	Format	Interactivity Type (IT)	Learning Resource Type (LRT)		Interactivity Level (IL)
1:Sequential(X):- Structure(X,"atomic"); Structure(X,"linear").	3:Visual(X):- Format(X,"video"); Format(X,"image");	7:Active(X):- IT(X,"active"); IT(X,"mixed").	9:Active(X):- LRT(X,"exercise"); LRT(X,"simulation"); LRT(X,"questionnaire"); LRT(X,"exam"); LRT(X,"experiment"); LRT(X,"problem statem."); LRT(X,"self assessment").	12:Intuitive(X):- LRT(X,"diagram").	15:Active(X):- IL(X,"medium"); IL(X,"high"); IL(X,"very high").
2:Global(X):- Structure(X,"collection"); Structure(X,"networked"); Structure(X,"hierarchical").	4:Verbal(X):- Format(X,"text"); Format(X,"audio");	8:Reflective(X):- IT(X,"expositive"); IT(X,"mixed").	10:Reflective(X):- LRT(X,"diagram"); LRT(X,"figure"); LRT(X,"graph"); LRT(X,"index"); LRT(X,"slide"); LRT(X,"table"); LRT(X,"narrative text"); LRT(X,"lecture").	13:Visual(X):- LRT(X,"diagram"); LRT(X,"figure"); LRT(X,"graph"); LRT(X,"experiment").	16:Reflective(X):- IL(X,"very low"); IL(X,"low"); IL(X,"medium").
	5:Active(X):- Format(X,"application").		11:Sensitive(X):- LRT(X,"simulation"); LRT(X,"figure"); LRT(X,"graph"); LRT(X,"index"); LRT(X,"table"); LRT(X,"experiment"); LRT(X,"self assessment").	14:Verbal(X):- LRT(X,"exercise"); LRT(X,"questionnaire"); LRT(X,"index"); LRT(X,"table"); LRT(X,"narrative text"); LRT(X,"exam"); LRT(X,"problem statem."); LRT(X,"self assessment"); LRT(X,"lecture").	
	6:Reflective(X):- Format(X,"video"); Format(X,"audio"); Format(X,"image").				

Figure 3. Regras de mapeamento de metadados de OAs que satisfazem EAs do modelo FSLSM.

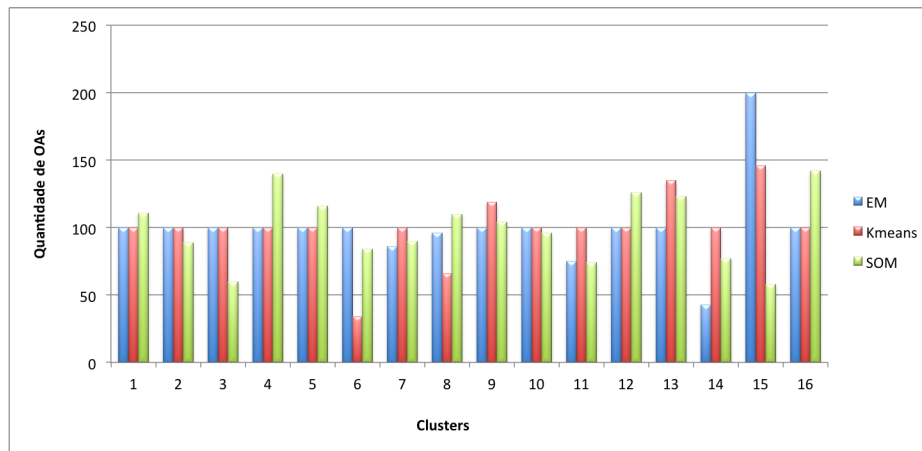


Figure 4. Comparativo da quantidade de OAs em cada cluster.

plataforma em questão. A plataforma gera OAs para cada aula ministrada e os armazena em uma base de conhecimento, que serve de entrada para o módulo proposto. Uma vez executado e com o agrupamento gerado, esse módulo serve como entrada de dados para o módulo de tratamento de conteúdo do CX, no qual motores de recomendação e apresentação se encarregam de aplicar algoritmos especializados para apresentação personalizada do conteúdo aos estudantes.

7. Conclusão

A utilização de OAs e EAs facilita o processo de ensino e aprendizagem, apoia o tutor para gerar melhores conteúdos e ajuda também o aluno com a proposta de recomendar conteúdo que sejam mais habituais com as características

dos perfis. Logo, existe a relevância em avaliar estratégias para recomendação de conteúdo para facilitar e apoiar os usuário em sistema adaptativos inteligentes.

É importante ressaltar a comparação entre três técnicas visando a melhor clusterização. Foi possível identificar a melhor técnica com sucesso utilizando métricas de validações consistentes. Desta forma, a abordagem proposta pode contribuir muito com o processo de recomendação personalizada de conteúdo em sistemas adaptativos, pois resultados promissores foram obtidos durante os experimentos.

Pode-se observar que a relevância dos OAs em relação aos EAs são muito importantes pelo fato de que um estudado tem mais facilidade em aprender conforme seu perfil. Com isso é possível facilitar o processo de recomendação personalizada de conteúdo considerando EAs em ambientes

Table 2. VALIDAÇÃO DOS RESULTADOS DA CLUSTERIZAÇÃO

KMeans			EM			SOM		
C	Qtd	Classes	Qtd	Classes	Qtd	Classes		
1	100	SenRefGloVis	100	SenRefGloVis	111	IntRefSeqVis , IntRefGloVis		
2	100	SenRefSeqVis	100	IntRefSeqVer	89	IntRefGloVis , IntRefSeqVis		
3	100	IntAtiGloVis	100	SenAtiGloVis	60	IntAtiSeqVis , IntAtiGloVis		
4	100	IntAtiGloVer	100	IntAtiGloVer	140	IntAtiGloVis , IntAtiSeqVis		
5	100	IntRefGloVer	100	IntAtiSeqVer	116	SenRefSeqVis , SenRefGloVis		
6	34	SenAtiGloVis	100	IntRefSeqVis	84	SenRefGloVis , SenRefSeqVis		
7	100	SenAtiSeqVer	86	SenAtiSeqVer	90	SenAtiSeqVis , SenAtiGloVis		
8	66	SenAtiGloVis	96	IntAtiSeqVis	110	SenAtiGloVis , SenAtiSeqVis		
9	119	IntRefSeqVis , IntAtiSeqVis	100	SenRefSeqVer	104	SenRefGloVer , SenRefSeqVer		
10	100	SenAtiGloVer	100	IntRefGloVis	96	SenRefSeqVer , SenRefGloVis		
11	100	SenAtiSeqVis	75	SenAtiSeqVis , IntAtiSeqVis	74	SenAtiSeqVer , SenAtiGloVer		
12	100	IntRefGloVis	100	IntRefGloVer	126	SenAtiGloVer , SenAtiSeqVer		
13	135	IntAtiSeqVis , IntAtiSeqVer	100	IntAtiGloVis	123	IntRefSeqVer , IntRefGloVer		
14	100	SenRefGloVer	43	SenAtiSeqVis , SenAtiSeqVer	77	IntRefGloVer , IntRefSeqVer		
15	146	IntRefSeqVer , IntAtiSeqVer	200	SenAtiGloVer , SenRefGloVer	58	IntAtiSeqVer , IntAtiGloVer		
16	100	SenRefSeqVer	100	SenRefSeqVis	142	IntAtiGloVer , IntAtiSeqVer		
M	P: 0,945	F: 0,923	P: 0,945	F: 0,928	P: 0,562	F : 0,553		

Table 3. GRAU DE PERTINÊNCIA

C	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
16	0.05	0	0.07	0.01	0.04	0	0	0.03	0	0.01	0.01	0	0	0.01	0.01	0.82




Figure 5. Proposta de arquitetura

educacionais.

Para um trabalho futuro tem-se o objetivo de avaliar os conteúdos gerados para cada estudante e criar um processo de filtragem mais refinado que considere o contexto dos OAs.

Agradecimentos

Os autores agradecem o apoio das agências de pesquisa e instituições CNPq, CAPES, FAPEMIG, PROPP/UFU e PET/MEC/SESU pelo apoio concedido a este trabalho.

References

- [1] M. d. C. Borba and M. G. Penteado, "Informática na educação," *Belo Horizonte: Autêntica*, 2001.
- [2] M. d. ALMEIDA, "Educação a distância na internet: abordagens e contribuições dos ambientes digitais de aprendizagem. 2003," Disponível em: www.scielo.br/pdf/ep-v29n2/a10v29n2.pdf, 2011.
- [3] T. Z. Torres and S. F. do Amaral, "Aprendizagem colaborativa e web 2.0: proposta de modelo de organização de conteúdos interativos," *Educação Temática Digital*, vol. 12, p. 49, 2011.
- [4] D. F. Audino and R. da Silva Nascimento, "Objetos de aprendizagem—diálogos entre conceitos e uma nova proposição aplicada à educação," *Revista Contemporânea de Educação*, vol. 5, no. 10, 2012.
- [5] R. M. Felder and L. K. Silverman, "Learning and teaching styles in engineering education," *Engineering education*, vol. 78, no. 7, pp. 674–681, 1988.
- [6] L. Margarida, R. Tarouco, and M.-c. J. M. Fabre, "Reusabilidade de objetos educacionais," pp. 1–11, 2003.
- [7] S. C. Cazella, E. Reategui, M. Machado, and J. Barbosa, "Recomendação de objetos de aprendizagem empregando filtragem colaborativa e competências," *Simpósio Brasileiro de Informática na Educação (SBIE)*, 2009.
- [8] L. Zaina, G. Bressan, M. Cardieri, and J. F. R. Júnior, "e-lors: Uma abordagem para recomendação de objetos de aprendizagem," *Revista Brasileira de Informática na Educação*, vol. 20, no. 1, p. 04, 2012.
- [9] S. C. Cazella, P. Behar, D. Schneider, K. K. da Silva, and R. Freitas, "Desenvolvendo um sistema de recomendação de objetos de aprendizagem baseado em competências para a educação: relato de experiências," in *Anais do Simpósio Brasileiro de Informática na Educação*, vol. 23, no. 1, 2012.
- [10] H. dos Santos, C. Cechinel, R. Araújo, and D. Brauner, "Recomendação de objetos de aprendizagem utilizando filtragem colaborativa: Uma comparação entre abordagens de pré-processamento

- por meio de clusterização,” in *Anais do Simpósio Brasileiro de Informática na Educação*, vol. 26, no. 1, 2015, p. 1127.
- [11] M. F. R. Casagrande, G. Kozima, and R. Willrich, “Técnica de recomendação baseada em metadados para repositórios digitais voltados ao ensino,” *Revista Brasileira de Informática na Educação*, vol. 23, no. 02, p. 70, 2015.
 - [12] A. Zapata and V. H. Menendez, “Discovering Learning Objects Usability Characteristics,” 2009.
 - [13] C. Romero, S. Ventura, J. A. Delgado, and P. De Bra, “Personalized links recommendation based on data mining in adaptive educational hypermedia systems,” pp. 292–306, 2007.
 - [14] R. Riding and S. Rayner, *Cognitive styles and learning strategies: Understanding style differences in learning and behavior*. Routledge, 2013.
 - [15] A. L. Franzoni, S. Assar, B. Defude, and J. Rojas, “Student learning styles adaptation method based on teaching strategies and electronic media,” in *Advanced Learning Technologies, 2008. ICALT’08. Eighth IEEE International Conference on*. IEEE, 2008, pp. 778–782.
 - [16] F. A. Dorça, L. V. Lima, M. A. Fernandes, and C. R. Lopes, “Detecção e correção automática de estilos de aprendizagem em sistemas adaptativos para educação,” *Revista de Informática Teórica e Aplicada*, vol. 18, no. 2, pp. 178–204, 2011.
 - [17] D. A. Wiley, *Instructional use of learning objects*. Agency for Instructional Technology, 2001.
 - [18] IEEE, “IEEE Standard for Learning Object Metadata,” pp. i–32+, 2002.
 - [19] A. Felfernig, G. Friedrich, B. Gula, M. Hitz, T. Kruggel, G. Leitner, R. Melcher, D. Riepan, S. Strauss, E. Teppan *et al.*, “Persuasive recommendation: serial position effects in knowledge-based recommender systems,” in *Persuasive technology*. Springer, 2007, pp. 283–294.
 - [20] W. Hodgins, E. Duval *et al.*, “Draft standard for learning object metadata,” *IEEE*, vol. 1484, pp. 1–2002, 2002.
 - [21] R. S. Michalski, J. G. Carbonell, and T. M. Mitchell, *Machine learning: An artificial intelligence approach*. Springer Science & Business Media, 2013.
 - [22] T. M. Mitchell, “Machine learning. 1997,” *Burr Ridge, IL: McGraw Hill*, vol. 45, no. 37, pp. 870–877, 1997.
 - [23] J. MacQueen *et al.*, “Some methods for classification and analysis of multivariate observations,” in *Proceedings of the fifth Berkeley symposium on mathematical statistics and probability*, vol. 1, no. 14. Oakland, CA, USA., 1967, pp. 281–297.
 - [24] A. P. Dempster, N. M. Laird, and D. B. Rubin, “Maximum likelihood from incomplete data via the em algorithm,” *Journal of the royal statistical society. Series B (methodological)*, pp. 1–38, 1977.
 - [25] P. Kohonen, Teuvo, “Self-organizing maps of symbol strings,” *Neurocomputing*, vol. 21, no. 1, pp. 19–30, 1998.
 - [26] U. M. Fayyad, G. Piatetsky-Shapiro, P. Smyth, and R. Uthurusamy, “Advances in knowledge discovery and data mining,” 1996.
 - [27] V. C. Carvalho, F. A. Dorça, R. G. Cattelan, and R. D. Araújo, “Uma abordagem para recomendação automática e dinâmica de objetos de aprendizagem baseada em estilos de aprendizagem,” 2014.
 - [28] F. A. Dorça, L. V. Lima, M. A. Fernandes, and C. R. Lopes, “Automatic student modeling in adaptive educational systems through probabilistic learning style combinations: a qualitative comparison between two innovative stochastic approaches,” *Journal of the Brazilian Computer Society*, vol. 19, no. 1, pp. 43–58, 2013.
 - [29] M. Hall, E. Frank, G. Holmes, B. Pfahringer, P. Reutemann, and I. H. Witten, “The weka data mining software: an update,” *ACM SIGKDD explorations newsletter*, vol. 11, no. 1, pp. 10–18, 2009.
 - [30] J. Vesanto, J. Himberg, E. Alhoniemi, J. Parhankangas *et al.*, “Self-organizing map in matlab: the som toolbox,” in *Proceedings of the Matlab DSP conference*, vol. 99, 1999, pp. 16–17.
 - [31] H. Xiong, J. Wu, and J. Chen, “K-means clustering versus validation measures: a data-distribution perspective,” *Systems, Man, and Cybernetics, Part B: Cybernetics, IEEE Transactions on*, vol. 39, no. 2, pp. 318–331, 2009.
 - [32] R. D. Araújo, T. Brant-Ribeiro, R. G. Cattelan, S. A. De Amo, and H. N. Ferreira, “Personalization of interactive digital media in ubiquitous educational environments,” in *Systems, Man, and Cybernetics (SMC), 2013 IEEE International Conference on*. IEEE, 2013, pp. 3955–3960.